

**MINISTÉRIO DA DEFESA
EXÉRCITO BRASILEIRO
DEPARTAMENTO DE CIÊNCIA E TECNOLOGIA
INSTITUTO MILITAR DE ENGENHARIA
Seção de Engenharia de Sistemas / SE 8**

**Proposta de Tema de Dissertação de Mestrado
Curso: Mestrado em Sistemas e Computação**

**Sistema de Localização de Objetos para Apoio a um
Assistente Robótico Móvel na Casa Inteligente**

Aluno: Fulano

Orientador: Paulo F. F. Rosa, Ph.D

Data de Apresentação no SE/8:
Rio de Janeiro, 30 de setembro de 2013

Título da Dissertação

Título da Tese:

Sistema de Localização de Objetos para Apoio a um Assistente Robótico Móvel na Casa Inteligente

Título da Capa:

Sistema de Localização de Objetos para Apoio a um Assistente Robótico Móvel na Casa Inteligente

Área de Concentração:

Tecnologias e Sistemas de Computação

Linha de Pesquisa:

Tecnologias para Tratamento e Transmissão da Informação

Sumário

1	Modelagem	4
2	Algoritmo Genético	4
2.1	O processo	4
2.2	Limitações	5
2.3	Referências	6
3	Logica Nebulosa	6
3.1	Introdução	6
3.2	Modelo Aditivo Padrão(SAM)	6
3.3	Limitações	7

1 Modelagem

Pode-se observar que, como os métodos **Algoritmos Genéticos**, *Simulated Annealing* e *Ant Colony Optimization* necessitam que um problema de otimização seja definido. Logo é necessário definir um modelo do problema e uma função associada ao modelo para serem implementados. Isso implica que é necessário definir a arquitetura da inteligência a ser modelada. Logo, para que seja possível a modelagem de diferentes inteligências, será necessário analisar a eficiência da otimização de cada arquitetura para que seja escolhida a mais eficiente.

O método da Lógica Fuzzy também necessita que uma modelagem para o sistema a ser considerado seja definida. Isso também restringe a generalidade dos modelos que se enquadram nessa modelagem.

Já o a **Rede Neural** define implicitamente a estrutura interna que minimiza a diferença entre a saída real e a saída desejada. Entretanto, é necessário definir a topologia mais adequada para o problema em questão. Também, apesar de não ser necessário, pode-se decompor o problema em subproblemas e “atribuir redes neurais um subconjunto de tarefas que coincidem com suas capacidades inerentes” (pag. 29 HAYKIN, 2001) com o objetivo de aumentar a adaptabilidade da rede. Apesar de ser uma modelagem para a arquitetura da inteligência a ser mapeada, não representa uma restrição tão considerável quando a das abordagens citadas anteriormente.

2 Algoritmo Genético

Um *algoritmo genético* é uma heurística de busca que procura imitar a seleção natural que ocorre no processo evolucionário dos organismos vivos.

Nessa heurística, uma população de soluções (também chamadas de indivíduos ou fenótipos) para problemas de otimização é evoluída para conseguir soluções melhores. Cada solução possui um conjunto de propriedades (cromossomos ou genótipos) que podem ser mutados ou alterados.

Os requerimentos são, tipicamente:

- uma representação genética da solução
- uma função de aptidão para avaliação da solução

2.1 O processo

O processo é iniciado com uma população com propriedades geradas aleatoriamente.

A iteração da heurística se dá em 3 etapas:

- procriação: indivíduos são pareados e é aplicada a operação de cruzamento (*crossover*)
- mutação: alguns indivíduos são selecionados e é aplicada a operação de mutação (*mutation*)
- seleção: é usada a função de aptidão para descartar os indivíduos menos aptos restando as soluções que de fato trouxeram alguma melhoria.

As condições mais comuns para terminação do processo são as seguintes:

- encontrada uma solução que atende os requisitos mínimos
- número fixo de gerações alcançado
- recursos alocados (tempo ou dinheiro) alcançados
- a melhor solução alcançou um patamar estável em que mais iterações não produzem soluções melhores
- inspeção manual

2.2 Limitações

As limitações mais comuns no emprego de um algoritmo genético são:

- Funções de avaliação computacionalmente caras tornam essa heurística ineficiente.
- Não escala bem com a complexidade, isto é, quando o número de elementos expostos a mutação é grande o espaço de busca cresce exponencialmente. Por isso, na prática algoritmos genéticos são usados para, por exemplo, projetar uma hélice e não um motor.
- A melhor solução é relativa às outras soluções, por isso o critério de parada não é muito claro em alguns problemas.
- Em muitos problemas os algoritmos genéticos tendem a convergir para um ótimo local ou as vezes pontos arbitrários em vez do ótimo global.
- É difícil aplicar algoritmos genéticos para conjunto de dados dinâmicos. Pois as soluções podem começar a convergir para um conjunto de dados que já não é mais válido.
- Algoritmos genéticos não conseguem resolver eficientemente problemas em que a avaliação é binária (certo/errado), como em problemas de decisão. Nesse caso buscas aleatórias convergem tão rápido quanto essa heurística.
- Para problemas mais específicos existem outras heurísticas que encontram a solução mais rapidamente.

2.3 Referências

- Genetic algorithm

3 Logica Nebulosa

(Fuzzy)

3.1 Introdução

Sistemas nebulosos aproximam funções. Eles são aproximadores universais se usarem regras suficientes. Neste sentido sistemas difusos podem modelar qualquer função ou sistema contínuos. Aqueles sistemas podem vir tanto da física quanto da sociologia, bem como da teoria do controle ou do processamento de sinais. [ref KOSKO]

A qualidade da aproximação difusa depende da qualidade das regras. Na prática especialistas sugerem regras difusas ou aprendem-nas através de esquemas neurais através de dados e ajustam as regras com novos dados. Os resultados sempre aproximam alguma função não-linear desconhecida que pode mudar com o tempo. Melhores cérebros e melhores redes neurais resultam em melhores aproximações. [ref KOSKO]

3.2 Modelo Aditivo Padrão(SAM)

O sistema difuso $F : \mathbb{R}^n \mathbb{R}^p$ é em si uma árvore de regras rasa e extensa. É um aproximador por antecipação. Existem m regras da forma "Se X é conjunto difuso A então Y é conjunto difuso B ". A partir desse nível o sistema depende cada vez menos em palavras.

Cada entrada x aciona parcialmente todas as regras em paralelo. Então o sistema age como um processador associativo a medida que calcula a saída $F(x)$. Essas regras relacionam os conjuntos A_j e B_j , gerando o caminho difuso $A_j x B_j$. Na prática, é utilizado o produto para definir $a_j x b_j(x, y) = a_j(x).b_j(y)$. Esta é a parte "padrão" no SAM. A parte "aditiva" se refere ao fato de a entrada x acionar a j -ésima regra em um grau $a_j(x)$ e o sistema soma os acionamentos ou partes escaladas dos conjuntos escalados $a_j(x)B_j$:

$$F(x) = \frac{\sum w_i.a_j(x).V_j.c_j}{\sum w_j.a_j(x).V_j} \quad (1)$$

Com o volume/área V_j e o centróide c_j são dados por:

$$V_j = \int b_j(y_1, \dots, y_{p_{\mathbb{R}^p}}) dy_1 \dots dy_p > 0 \quad (2)$$

$$c_j = \frac{\int y \cdot b_j(y_1, \dots, y_{p_{\mathbb{R}^p}}) dy_1 \dots dy_p}{V_j} \quad (3)$$

(colocar figura e exemplo)

3.3 Limitações

(KOSKO, BART; **Fuzzy Engineering**, New Jersey, USA 1997) pág. 17

Jan Lucas de Lima Segre (10417)
Aluno

Victor Bramigk (??)
Aluno

Paulo F. F. Rosa, Ph.D
Orientador

IME, em 30 de setembro de 2013