

MINISTÉRIO DA DEFESA
EXÉRCITO BRASILEIRO
DEPARTAMENTO DE CIÊNCIA E TECNOLOGIA
IME - INSTITUTO MILITAR DE ENGENHARIA
CURSO DE GRADUAÇÃO EM ENGENHARIA DA COMPUTAÇÃO

CAMILA ANTONACCIO WANOUS
JOÃO LUIZ DO PRADO NETO
THIAGO DE PAULA VASCONCELOS

CONECTIVIDADE ALGÉBRICA E SEUS AUTOVETORES NA
CLASSE DAS ÁRVORES

Rio de Janeiro
2013

INSTITUTO MILITAR DE ENGENHARIA

ANÁLISE DE LOGS DE JOGOS DA SSL (ROBOCUP)

Análise de logs dos jogos de futebol de robôs da Robocup

Orientador: Paulo F. F. Rosa - Ph.D

Rio de Janeiro
2013

c2013

INSTITUTO MILITAR DE ENGENHARIA
Praa General Tibrcio, 80-Praia Vermelha
Rio de Janeiro-RJ CEP 22290-270

Este exemplar de propriedade do Instituto Militar de Engenharia, que poder inclu-lo em base de dados, armazenar em computador, microfilmarm ou adotar qualquer forma de arquivamento.

permitida a meno, reproduo parcial ou integral e a transmissio entre bibliotecas deste trabalho, sem modificao de seu texto, em qualquer meio que esteja ou venha a ser fixado, para pesquisa acadmica, comentrios e citaes, desde que sem finalidade comercial e que seja feita a referncia bibliogrfica completa.

Os conceitos expressos neste trabalho so de responsabilidade do(s) autor(es) e do(s) orientador(es).

Z34r Wanous, C., Prado, J., Vasconcelos, T.
Análise de logs de jogos da SSL (Robocup) / Camila Antonaccio Wanous, Joo Luiz do Prado Neto e Thiago de Paula Vasconcelos - Rio de Janeiro : Instituto Militar de Engenharia, 2013.

Iniciao Pesquisa (IP)- Instituto Militar de Engenharia - Rio de Janeiro, 2013.

1. Engenharia da computao. 2. Teoria espectral de grafo. 3. Vetor de Fiedler. 4. rvores de Tipo I e de Tipo II. Instituto Militar de Engenharia.

INSTITUTO MILITAR DE ENGENHARIA

CAMILA ANTONACCIO WANOUS

JOO LUIZ DO PRADO NETO

THIAGO DE PAULA VASCONCELOS

ANÁLISE DE LOGS DE JOGOS DA SSL (ROBOCUP)

Análise de logs dos jogos de futebol de robôs da Robocup

Orientador: Paulo F. F. Rosa - Ph.D

Aprovada em 08 de outubro de 2013 pela seguinte Banca Examinadora:

Paulo F. F. Rosa - Ph.D do IME - Presidente

Maj Julio Cesar Duarte - D.Sc. do IME

Rio de Janeiro
2013

RESUMO

O objetivo deste trabalho é prever como um time de futebol de robôs irá se comportar baseado somente nas posições e orientações de um conjunto discreto. Para isso, foram estudados os métodos da ACO(Ant Colony Optimization), SA(simulated Annealing), Algoritmo Genético, Lógica Nebulosa e Redes Neurais. A partir do estudo detalhado desse algoritmos definiu-se duas linhas principais de ação para a solução do problema: uma baseada em Logica Nebulosa e a outra baseada em Redes Neurais. Após um estudo mais aprofundado deseja-se implementar um processo de otimização em ambos os algoritmos para que o resultado seja refinado.

ABSTRACT

SUMÁRIO

CHAPTER 31	INTRODUÇÃO	6
1.1	Contextualização	6
SECTION 1.12	ANÁLISE DAS POSSÍVEIS ABORDAGENS	7
2.1	Logica Nebulosa	8
2.1.0.1	Introdução	8
2.1.0.2	Modelo Aditivo Padrão(SAM)	8
2.2	Otimização da Colônia de Formigas	9
2.2.1	Pseudo código da meta-heurística do ACO	9
2.3	Recozimento Simulado	10
2.3.0.1	Meta-heurística do SA	11
2.4	Algoritmo Genético	12
2.4.1	O processo	12
2.4.2	Limitações	13
2.4.3	Pseudo código de um Algoritmo Genético	13
2.4.4	Referências	13
2.5	Rede Neural	13
SECTION 2.53	PRÓXIMAS ETAPAS	15

1 INTRODUÇÃO

1.1 CONTEXTUALIZAÇÃO

O Laboratório de robótica da seção de computação do IME possui um time que participa de uma competição de futebol de robôs oficializada pela Robocup.

Essa competição consiste em partidas de futebol autônomas entre robôs com formato de cilindro de 18cm de diâmetro e 15cm de altura em um campo de 6m por 4m. Além disso o sistema de visão computacional é padronizado e centralizado. O importante é notar que a competição é autônoma e por isso há vários desafios envolvidos.

Um dos desafios é modelar o inimigo, de maneira geral modelar um time desconhecido mas com o intuito de conseguir prever com certa confiança suas decisões para tomar decisões melhores durante o jogo e conseguir um desempenho melhor.

As partidas são registradas e por isso podem ser feitas análises pré-jogo além de em tempo real. A principal vantagem é a liberdade sobre quão eficiente é o método de análise.

O objeto a ser estudado é a análise dos registros dessas partidas com foco principal em modelar um time desconhecido.

2 ANÁLISE DAS POSSÍVEIS ABORDAGENS

Como os métodos AG(Algoritmo Genético), SA e ACO são heurísticas de otimização, é necessário que o problema da aproximação de uma função seja reduzido a um problema de otimização. Uma abordagem é se escolher uma base finita de funções ortonormadas e minimizar a soma dos quadrados da norma da diferença entre os valores de treinamento e uma combinação linear das funções da base escolhida. Foi suposto, por simplicidade, que o espaço dos vetores um espaço vetorial com norma. Isso restringe o espaço solução, uma vez que apenas funções que são combinação linear das funções da base serão solução. O método da Lógica Fuzzy, conforme exposto anteriormente, necessita que um conjunto de regras seja definido. Essas regras podem ser geradas a partir de uma análise mais detalhada do problema, mas também podem ser aprendidas via rede neural.

Já a Rede Neural define implicitamente a estrutura interna que minimiza a diferença entre a saída real e a saída desejada. Entretanto, é necessário definir a topologia mais adequada para o problema em questão. Também, apesar de não ser necessário, pode-se decompor o problema em subproblemas e "atribuir redes neurais um subconjunto de tarefas que coincidem com suas capacidades inerentes" (pag. 29 HAYKIN, 2001) com o objetivo de aumentar a adaptabilidade da rede. Apesar de ser uma modelagem para a arquitetura da inteligência a ser mapeada, não representa uma restrição tão considerável quando a das abordagens citadas anteriormente.

Com base nisso, as seguintes abordagens foram estabelecidas:

- a) Utilizar Logica Fuzzy com regras geradas através de uma rede neural.
- b) Utilizar Rede Neural com uma topologia mista;

Na primeira abordagem, pretende-se utilizar os métodos de otimização para se encontrar a melhor topologia de rede neural que melhor otimiza o conjunto de regras buscado.

Pretende-se também, na segunda abordagem, utilizar os métodos de otimização descritos anteriormente para se encontrar a melhor topologia que aproxima da melhor maneira.

2.1 LOGICA NEBULOSA

2.1.0.1 INTRODUÇÃO

Sistemas nebulosos aproximam funções. Eles são aproximadores universais se usarem regras suficientes. Neste sentido sistemas difusos podem modelar qualquer função ou sistema contínuos. Aqueles sistemas podem vir tanto da física quanto da sociologia, bem como da teoria do controle ou do processamento de sinais. [ref KOSKO]

A qualidade da aproximação difusa depende da qualidade das regras. Na prática especialistas sugerem regras difusas ou aprendem-nas através de esquemas neurais através de dados e ajustam as regras com novos dados. Os resultados sempre aproximam alguma função não-linear desconhecida que pode mudar com o tempo. Melhores cérebros e melhores redes neurais resultam em melhores aproximações. [ref KOSKO]

2.1.0.2 MODELO ADITIVO PADRÃO(SAM)

O sistema difuso $F : \mathbb{R}^n \rightarrow \mathbb{R}^p$ é em si uma árvore de regras rasa e extensa. É um aproximador por antecipação. Existem m regras da forma "Se X é conjunto difuso A então Y é conjunto difuso B ". A partir desse nível o sistema depende cada vez menos em palavras.

Cada entrada x aciona parcialmente todas as regras em paralelo. Então o sistema age como um processador associativo a medida que calcula a saída $F(x)$. Essas regras relacionam os conjuntos A_j e B_j , gerando o caminho difuso $A_j x B_j$. Na prática, é utilizado o produto para definir $a_j x b_j(x, y) = a_j(x) \cdot b_j(y)$. Esta é a parte "padrão" no SAM. A parte "aditiva" se refere ao fato de a entrada x acionar a j -ésima regra em um grau $a_j(x)$ e o sistema soma os acionamentos ou partes escaladas dos conjuntos escalados $a_j(x)B_j$:

$$F(x) = \frac{\sum w_i \cdot a_i(x) \cdot V_i \cdot c_i}{\sum w_j \cdot a_j(x) \cdot V_j} \quad (2.1)$$

Com o volume/área V_j e o centróide c_j são dados por:

$$V_j = \int b_j(y_1, \dots, y_p)_{\mathbb{R}^p} \cdot dy_1 \dots dy_p > 0 \quad (2.2)$$

$$c_j = \frac{\int y \cdot b_j(y_1, \dots, y_p)_{\mathbb{R}^p} \cdot dy_1 \dots dy_p}{V_j} \quad (2.3)$$

(KOSKO, BART; **Fuzzy Engineering**, New Jersey, USA 1997) pág. 17

2.2 OTIMIZAÇÃO DA COLÔNIA DE FORMIGAS

Na busca por alimento, as formigas utilizam de feromônios para encontrar o melhor caminho. Isso acontece da seguinte maneira: cada formiga deposita feromônio ao se deslocar. A partir da avaliação da quantidade de feromônio depositada por formigas que já passaram pelo local, formigas subsequentes tem mais probabilidade de se mover em rotas que tem mais feromônios. Ao decorrer do tempo os feromônios vão evaporando, apagando rastros que não foram reforçados. Com isso, caminhos que são percorridos por mais formigas tem mais chance de serem percorridos por outras formigas do que aqueles que foram percorridos por menos formigas e caminhos que foram percorridos há pouco tempo tem mais chance de serem percorridos que caminhos percorridos há muito tempo. A quantidade de feromônio depositado é mais intensa no trajeto de volta, quando a comida foi encontrada. Outro fator que é levado em consideração é a qualidade da comida encontrada, de maneira que mais feromônio é depositado quanto melhor for a fonte de alimento encontrada. A medida que mais formigas exploram o local e encontram alimento, esse procedimento tende a otimizar o trajeto entre a fonte de alimento e a colônia.

Apesar dessa heurística utilizada pelas formigas ser interessante para se resolver problemas combinatórios do tipo NP (i.e., com complexidade não polinomial), são necessários algumas adaptações na construção de um algoritmo computacional.

A seguir é apresentado a meta-heurística do ACO (*Ant Colony Optimization*) algoritmo, juntamente com observações relacionadas as diferenças entre a heurística do ACO e o comportamento natural das formigas descrito anteriormente.

2.2.1 PSEUDO CÓDIGO DA META-HEURÍSTICA DO ACO

A meta-heurística do ACO pode ser subdividida em três partes, conforme proposto por (Dorigo, Marco; 2004): *ConstruirSolucoesFormigas*, *AtualizarFeromonios* e *AcoesGlobais*. *ConstruirSolucoesFormigas* gerencia a movimentação de uma colônia de formigas em torno dos nós vizinhos. A escolha do próximo nó é feita através de uma decisão estocástica que é função da quantidade de feromônio no nós vizinhos e informação heurística. Quando uma formiga encontra uma solução, ou enquanto a solução é construída, esta avalia a qualidade da solução (completa ou parcial) que será utilizada pelo procedimento *AtualizarFeromonios* para decidir a quantidade de feromônio que será depositada. Outro procedimento relevante na construção da solução é a eliminação de possíveis ciclos, utilizado por exem-

plo, no problema do caixeiro viajante.

AtualizarFeromonios é o processo que atualiza os traços de feromônio depositados pelas formigas no espaço de busca. Os traços de feromônio podem aumentar, caso uma formiga tenha visitado o nó/conexão em questão, ou diminuir, devido ao processo de evaporação do feromônio. Esse procedimento faz com que nós/conexões que foram visitados por muitas formigas ou por uma formiga e que tenha levado em uma solução boa aumentem a probabilidade de serem visitados por futuras formigas. Semelhantemente, reduz a probabilidade de que nós que não foram visitados por novas formigas por muitas iterações sejam visitados novamente. Logo, este procedimento evita a convergência a caminhos sub ótimos, favorecendo também a exploração de novas regiões do espaço de busca.

Por fim, o procedimento *AcoesGlobais* é utilizado para centralizar ações que não podem ser executadas pelas formigas individualmente. Um exemplo de ações desse tipo é a filtragem de soluções ou o favorecimento de regiões por meio de informações globais.

O procedimento *AgendarAtividade* não necessariamente é uma instrução sequencial. Pode-se, portanto, implementá-lo de maneira sequencial ou paralela, síncrona ou assincronamente. O tipo de abordagem que será utilizada depende das características do problema que se deseja resolver.

2.3 RECOZIMENTO SIMULADO

No processo de recozimento de um metal, a quantidade de energia interna livre esta intrinsecamente relacionada ao processo de resfriamento em que o metal é submetido. Quanto mais rápido se resfriam um metal mais energia é armazenada internamente. Isso pode ser explicado considerando que o tempo que a estrutura leva para atingir o estado de menor energia é maior que o disponível devido a redução da mobilidade dos átomos com o decaimento da temperatura. Com efeito, quanto maior a taxa de resfriamento maior o número de defeitos na estrutura do sólido e menor o tamanho médio dos grãos. Quando se reduz a taxa de resfriamento, há uma maior chance de se atingir configurações mais estáveis. Como resultado, a energia interna é reduzida. De acordo com (BERTSIMAS, Dimitris; TSITSIKLIS, John; 1993), pode-se modelar a probabilidade p_{ij} de uma configuração atômica $\{r_i\}$ com energia $E\{r_i\}$ passar para a configuração $\{r_j\}$ com energia $E\{r_j\}$ na temperatura T como:

$$p_{ij} = \begin{cases} 1 & \text{se } E\{r_j\} \leq E\{r_i\} \\ \exp\left\{-\frac{(E\{r_j\}-E\{r_i\})}{k_B.T}\right\} & \text{se } E\{r_j\} > E\{r_i\} \end{cases} \quad (2.4)$$

Onde k_B é a constante de Boltzmann. Para se reduzir a energia livre, é necessário que uma rotina de resfriamento seja escolhida de acordo com o tipo de material a ser resfriado. Conforme proposto por Kirikpartrick, Gellett e Vechin (1983) e Cerny (1985), pode-se desenvolver uma heurística probabilística para se encontrar o mínimo global de uma função custo que possua vários mínimos locais fazendo-se uma analogia com o fenômeno físico descrito acima. A meta-heurística induzida por este processo é chamada de meta-heurística *Simulated Annealing* (Recozimento Simulado), ou SA, apresentado a seguir.

2.3.0.1 META-HEURÍSTICA DO SA

De acordo com (BERTSIMAS, Dimitris; TSITSIKLIS, John; 1993), os elementos básicos da meta-heurística do SA para a resolução de um problema combinatório são:

- a) Um conjunto finito S .
- b) Um função custo J de imagem real definida em S . Seja $S^* \subset S$ o conjunto de todos os mínimos globais da função J , suposto subconjunto próprio.
- c) Para cada $i \in S$ um conjunto $S(i) \subset S - \{i\}$, chamado de conjunto das vizinhos de i .
- d) Para cada i , uma coleção de coeficientes positivos q_{ij} , $j \in S(i)$, tal que $\sum_{j \in S(i)} q_{ij} = 1$.
- e) Uma função não crescente $T : \mathbf{N} \rightarrow (0, \infty)$, chamada de rotina de resfriamento. Aqui \mathbf{N} representa o conjunto de inteiros positivos, e $T(t)$ é chamada de *temperatura* no tempo t .
- f) Um estado inicial $x(0) \in S$.

Com base na definições acima, tem-se o seguinte pseudo código para a meta-heurística do SA:

No algoritmo (??), o procedimento *AtualizarTemperetura* executa a rotina de resfriamento através da função $T(t)$ definida anteriormente. Já o procedimento *EscolherVisinho* escolhe aleatoriamente um dos elementos da vizinhança do vértice atual i .

2.4 ALGORÍTIMO GENÉTICO

Um *algoritmo genético* é uma heurística de busca que procura imitar a seleção natural que ocorre no processo evolucionário dos organismos vivos.

Nessa heurística, uma população de soluções (também chamadas de indivíduos ou fenótipos) para problemas de otimização é evoluída para conseguir soluções melhores. Cada solução possui um conjunto de propriedades (cromossomos ou genótipos) que podem ser mutados ou alterados.

Os requerimentos são, tipicamente:

- uma representação genética da solução
- uma função de aptidão para avaliação da solução

2.4.1 O PROCESSO

O processo é iniciado com uma população com propriedades geradas aleatoriamente.

A iteração da heurística se dá em 3 etapas:

- procriação: indivíduos são pareados e é aplicada a operação de cruzamento (*crossover*)
- mutação: alguns indivíduos são selecionados e é aplicada a operação de mutação (*mutation*)
- seleção: é usada a função de aptidão para descartar os indivíduos menos aptos restando as soluções que de fato trouxeram alguma melhora.

As condições mais comuns para terminação do processo são as seguintes:

- encontrada uma solução que atende os requisitos mínimos
- número fixo de gerações alcançado
- recursos alocados (tempo ou dinheiro) alcançados
- a melhor solução alcançou um patamar estável em que mais iterações não produzem soluções melhores
- inspeção manual

2.4.2 LIMITAÇÕES

As limitações mais comuns no emprego de um algoritmo genético são:

- Funções de avaliação computacionalmente caras tornam essa heurística ineficiente.
- Não escala bem com a complexidade, isto é, quando o número de elementos expostos a mutação é grande o espaço de busca cresce exponencialmente. Por isso, na prática algoritmos genéticos são usados para, por exemplo, projetar uma hélice e não um motor.
- A melhor solução é relativa às outras soluções, por isso o critério de parada não é muito claro em alguns problemas.
- Em muitos problemas os algoritmos genéticos tendem a convergir para um ótimo local ou as vezes pontos arbitrários em vez do ótimo global.
- É difícil aplicar algoritmos genéticos para conjunto de dados dinâmicos. Pois as soluções podem começar a convergir para um conjunto de dados que já não é mais válido.
- Algoritmos genéticos não conseguem resolver eficientemente problemas em que a avaliação é binária (certo/errado), como em problemas de decisão. Nesse caso buscas aleatórias convergem tão rápido quanto essa heurística.
- Para problemas mais específicos existem outras heurísticas que encontram a solução mais rapidamente.

2.4.3 PSEUDO CÓDIGO DE UM ALGORÍTIMO GENÉTICO

2.4.4 REFERÊNCIAS

- Genetic algorithm
- Genetic Algorithms - Derek Bridge

2.5 REDE NEURAL

O termo mais apropriado é rede neural artificial, já que apenas rede neural pode se referir ao sistema biológico de nervos, no entanto dado o contexto desse texto e o uso consagrado do termo “rede neural”, esse será usado no lugar da versão mais explícita “rede neural artificial”.

Uma rede neural é um sistema inspirado no sistema nervoso central (em especial o cérebro) encontrado em muitos animais. A ideia básica é ter um grafo acíclico direcionado, DAG (do inglês *Directed Acyclic Graph*), em que cada nó abstrai um neurônio e é representado como uma função, alguns desses nós são responsáveis pela observação e outros pela saída e os nós de entrada alimentam os próximos nós até chegar nos nós de saída.

...

fontes:

- http://en.wikipedia.org/wiki/Neural_network
- http://en.wikipedia.org/wiki/Artificial_neural_network
- HAYKIN, S. Redes neurais princípios e prática.

3 PRÓXIMAS ETAPAS

As próximas etapas consistem em estudar a solução através dos métodos e das abordagens propostas de problemas mais simples para consolidar o estudo dos métodos estudados e analisar as topologias das redes neurais para que futuramente seja possível encontrar a topologia ótima e assim refinar os resultados da rede e das regras do sistema difuso.